
Problem Set 2: Big Data & Machine Learning

Juan Esteban Díaz Torres¹, Natalia Plata Ángel², Ángel David Ramírez Torres³ y Juan Pablo Grimaldos⁴

¹ 202020319 ² 202013152 ³ 202112704 ⁴ 202122627

[Repositorio.](#)

1. Introducción

El Estado colombiano enfrenta restricciones presupuestales que limitan su capacidad para desarrollar políticas públicas orientadas a reducir la pobreza entre los sectores más vulnerables. Para focalizar adecuadamente las ayudas sociales, es fundamental identificar quiénes son las personas en situación de vulnerabilidad, dónde se encuentran y cuál es el grado de su necesidad. En Colombia, esta labor recae en el Departamento Nacional de Planeación (DNP), responsable del diseño y administración del Sistema de Identificación de Potenciales Beneficiarios de Programas Sociales (SISBEN).

Desde 1995, el SISBEN ha sido el principal instrumento del Estado para clasificar a la población con base en sus condiciones de vida e ingresos, con el fin de que entidades como el Departamento de Prosperidad Social (DPS) puedan dirigir las ayudas sociales a quienes más las necesitan. Para construir la base de datos sobre la cual se fundamenta esta clasificación, el DPS diseña y aplica una encuesta de caracterización socioeconómica. A lo largo del tiempo, el SISBEN ha tenido cuatro versiones, en las cuales se han realizado cambios tanto en el enfoque como en la metodología de clasificación. En su primera versión, estudios como el de Camacho y Conover (2011) evidenciaron indicios de manipulación de los puntajes en torno a los umbrales que determinaban el acceso a ciertos programas sociales. En contraste, la versión más reciente (SISBEN IV), que entró en vigor en 2021, incorporó un nuevo enfoque basado en la capacidad de generación de ingresos de los hogares, además de una actualización del universo de registros, que no se renovaba desde 2011.

Para este trabajo, se utilizaron datos recolectados por el Departamento Administrativo Nacional de Estadística (DANE) en el marco de la misión “Empalme de las Series de Empleo, Pobreza y Desigualdad – MESE” (DANE, 2018). Esta base contiene variables socioeconómicas tanto a nivel individual como de hogar, relacionadas con el ingreso, nivel educativo, afiliación a la seguridad social, condiciones laborales y ubicación geográfica por departamento. Dichos datos resultan útiles para abordar el problema de la focalización de la pobreza por dos razones principales: (i) incluyen múltiples variables socioeconómicas asociadas con condiciones de vulnerabilidad, lo cual permite una caracterización precisa de los hogares pobres; y (ii) provienen de fuentes distintas al DPS, lo que demuestra que es posible complementar la información tradicionalmente utilizada para la clasificación de hogares en situación de pobreza (iii) el DANE tiene un alto nivel de credibilidad debido a sus altos estándares metodológicos, lo cual se refleja en una excelente calidad de datos.

Para predecir la condición de pobreza de los hogares, se aplicaron cuatro algoritmos de clasificación: Regresión Logística, Elastic Net, Random Forest y Adaptive Boosting. De estos, Random Forest obtuvo el mejor desempeño, alcanzando un puntaje de 0.6940 en la competencia de Kaggle. Este modelo resalta la relevancia de la inserción en el mercado laboral, las características del empleo y las condiciones de la vivienda como factores determinantes de la vulnerabilidad. Además, su buen desempeño sugiere la existencia de relaciones no lineales entre estas variables, lo que destaca la importancia de utilizar técnicas de aprendizaje automático para mejorar la focalización de las políticas sociales.

El buen desempeño de este modelo puede atribuirse a varios factores. En primer lugar, se per-

mitió una mayor profundidad en los árboles individuales, lo cual incrementa el ajuste de cada árbol al conjunto de entrenamiento. Además, este modelo utilizó un número significativamente mayor de árboles en comparación con los demás, lo que contribuyó a reducir la varianza y mejorar la estabilidad de las predicciones. Adicionalmente, el modelo tiene la capacidad de capturar de manera eficaz relaciones no lineales entre las variables, a diferencia de metodologías como Elastic Net o Boosting, que presentan limitaciones en este aspecto.

2. Descripción de los datos

2.1. Fuente

Los datos utilizados en este trabajo provienen del Departamento Administrativo Nacional de Estadística (DANE) y de la misión “Empalme de las Series de Empleo, Pobreza y Desigualdad – MESE”. El conjunto incluye cuatro subconjuntos de datos, divididos en entrenamiento y prueba, tanto a nivel de hogar como individual. La base contiene información de 231.128 hogares en todo el territorio nacional, junto con los datos de sus respectivos integrantes. Esta fuente resulta particularmente pertinente para el propósito de este trabajo, ya que proviene directamente del DANE, la entidad oficial encargada de la medición de la pobreza en Colombia. En consecuencia, la calidad de los datos es altamente confiable, dado el riguroso diseño muestral y los estándares metodológicos que caracterizan el trabajo de esta institución. Adicionalmente, es una fuente de datos diferente a la que se utiliza tradicionalmente para calcular el puntaje del SISBEN y focalizar las políticas sociales en Colombia, por lo que provee un enfoque distinto a este problema.

2.2. Procesamiento

Antes de iniciar la modelación para la predicción de la pobreza, se llevó a cabo un exhaustivo proceso de preparación de los datos. En primer lugar, se seleccionaron en la base de entrenamiento únicamente aquellas variables que también estaban presentes en la base de prueba. Esto se debió a que muchas de las variables numéricas asociadas a los ingresos de las personas y los hogares no se encontraban en la muestra de prueba, y no existía forma de recuperarlas a partir de las demás variables disponibles.

Posteriormente, se combinaron las bases de datos de hogares de entrenamiento y prueba para proceder a la limpieza de la muestra de hogares. Durante este proceso, se identificaron las variables con valores faltantes. Se constató que las variables referentes al monto que se paga por arriendo, a lo que se estima que pagaría si viviera en arriendo y al pago del crédito de vivienda presentaban una alta proporción de valores faltantes. Esto se debía a que estas preguntas se aplicaban de acuerdo al tipo de propiedad del hogar, de modo que los valores faltantes correspondían a hogares para los que no se realizaban dichas preguntas, lo que permitía su reemplazo por ceros. Además, se detectó que estas mismas variables tenían una marcada dispersión hacia la derecha, por lo que se procedió a acotarlas al percentil 99.5; esta elección de punto de corte se realizó con el objetivo de preservar los valores que pudieran corresponder a datos reales y no a errores de medición.

Asimismo, se procedió a limpiar la base de datos de personas, la cual contenía más variables con valores faltantes. Sin embargo, tras analizar detalladamente el diccionario de datos, se identificó que la mayoría de estos valores correspondían a preguntas no aplicables a ciertas personas según sus características. Por ejemplo, aquellas relativas al salario, primas y bonificaciones se formulaban únicamente a las personas ocupadas. Por ello, cuando una pregunta no era pertinente para un determinado grupo, se imputaron ceros en los valores faltantes correspondientes. Además, la variable de grado escolar tenía una mayor cantidad de valores faltantes en comparación con la variable de nivel educativo. Por ello, se imputaron los valores faltantes utilizando el promedio del grado escolar alcanzado para cada nivel educativo.

Por último, se agrupó la base de datos de personas a nivel de hogar, ya que esta es la unidad de

observación para la variable de resultado. Algunas variables se consolidaron mediante la suma total (por ejemplo, el número de menores de edad y las horas totales trabajadas en el hogar), otras mediante promedios (por ejemplo, la edad promedio y el grado escolar promedio), y otras mediante el cálculo de proporciones (por ejemplo, la proporción de ocupados que reciben primas y la proporción de personas con educación superior en el hogar).

2.3. Estadísticas descriptivas

Los hogares pobres relativo a los no pobres habitan en promedio en viviendas más pequeñas (por un cuarto), pagando arriendos más bajos, tienen en promedio una mujer y un menor de quince años más y son hogares más jóvenes (en promedio por nueve años). Los hogares pobres en promedio no tienen miembros que cuenten educación superior o que coticen pensión. En contraste, los hogares no pobres tienen en promedio un miembro con educación superior y la mitad de sus integrantes cotizan pensión. Los hogares pobres en promedio trabajan menos horas, sus miembros llevan menos meses en las empresas donde están empleados y tienen más miembros que tienen la seguridad social subsidiada. Lo anterior, parecería indicar que en promedio los hogares más pobres habitan viviendas de menor valor y por ende es probable que estén ubicadas en lugares con menos amenidades. Tiene padres que tienen trabajos informales más inestables, familias más jóvenes y numerosas, que podrían ser el reflejo de una menor planificación familiar, y los miembros de los hogares pobres tienen en promedio menores logros educativos. Esto se puede evidenciar con más detalle en las Tablas 1 y 2.

3. Modelos de clasificación

3.1. Regresión logística

Uno de los modelos utilizados para clasificar los hogares entre pobres y no pobres fue la regresión logística. Este modelo sirve para predecir la probabilidad (acotada entre 0 y 1) de que un hogar sea pobre o no lo sea. Luego se clasifican aquellos hogares con una probabilidad mayor al 50% de ser pobres como pobres, y aquellos por debajo de este punto de corte como no pobres. En este modelo se utilizaron las variables con mayor importancia de acuerdo con el modelo de Bosque Aleatorio en el conjunto X_2 que será explicado con mayor detalle en la sección de dicho modelo. Este modelo obtuvo una medida $F1$ de validación cruzada de 0.68.

3.2. Elastic Net

El segundo intento de predicción se realizó utilizando el método de regularización Elastic Net combinado con regresión logística para predecir si un hogar es pobre o no lo es. Este método combina las ventajas de Lasso y Ridge: por un lado, Lasso reduce la varianza del modelo al llevar algunos coeficientes exactamente a cero, lo que favorece la selección de variables; por otro lado, Ridge penaliza los coeficientes grandes para evitar el sobreajuste, sin eliminarlos completamente. Al combinar ambos enfoques, Elastic Net permite que algunos coeficientes se reduzcan a cero (como en Lasso), mientras que penaliza otros sin eliminarlos (como en Ridge), logrando así un equilibrio entre simplificación del modelo y retención de información relevante.

El modelo Elastic Net tiene dos hiperparámetros principales: α y λ . El parámetro α controla la combinación entre las penalizaciones de Lasso y Ridge: cuando $\alpha = 1$, el modelo se comporta como un Lasso puro; cuando $\alpha = 0$, actúa como un Ridge puro; y para valores intermedios ($0 < \alpha < 1$), se obtiene una combinación de ambas penalizaciones. Por lo tanto, α se encuentra en el intervalo $[0, 1]$. Por su parte, λ regula la magnitud de la penalización aplicada a los coeficientes del modelo: valores pequeños de λ permiten que el modelo se ajuste más a los datos (menor penalización), mientras que valores grandes hacen que los coeficientes se reduzcan más fuertemente hacia cero (mayor regularización). Este parámetro toma valores positivos en un rango amplio, típicamente explorado en una escala logarítmica, como por ejemplo entre 0.001 y 10, dependiendo del contexto y de la escala de los datos. La elección adecuada de estos hiperparámetros es crucial para lograr un buen equilibrio entre

sesgo y varianza, y se suele hacer mediante validación cruzada.

En esta ocasión, la elección de hiperparámetros se realizó por medio del método de validación cruzada de 10 particiones. El hiperparámetro α se buscó en un intervalo $(0, 1]$. Mientras tanto, λ se buscó en el intervalo $(0, 2]$. Se utilizaron grillas de 1000, 2000, 3000 y 5000 combinaciones de α y λ . No obstante, el mejor modelo de Elastic Net no se obtuvo utilizando una grilla para buscar los parámetros, sino utilizando la opción TuneLength que las combinaciones de hiperparámetros se van a explorar automáticamente durante el proceso de entrenamiento del modelo. Esto puede explicarse porque al utilizar el método de la grilla, el modelo hace saltos de un tamaño fijo entre un valor del hiperparámetro y el siguiente, por lo que el valor óptimo de alguno de los hiperparámetros puede encontrarse entre dos valores contenidos en la grilla. En la tabla 3 se puede ver las top 10 combinaciones de α y λ según su $F1$ halladas a través del proceso de validación cruzada. El modelo seleccionado en este proceso tiene un $\alpha = 0.4$ y un $\lambda = 0.00445108$ y un $F1$ de validación cruzada de 0.923. El desempeño de prueba de este modelo de acuerdo con la medida $F1$ de Kaggle fue de 0.67.

En este modelo se utilizaron la mayoría de las variables disponibles en la base de datos procesada. No obstante, en los casos en que una misma característica del hogar se encontraba agregada tanto como suma total como en forma de proporción de los integrantes, se optó por conservar únicamente las variables expresadas en proporciones. Esta decisión tuvo como objetivo evitar la inclusión de variables redundantes que no aportan variación adicional al modelo, al tiempo que se reducía la carga computacional. Adicionalmente, se incorporaron términos polinómicos para algunas variables clave —como la edad promedio del hogar, el grado escolar promedio, las horas trabajadas en el hogar y el tiempo en el empleo actual— con el fin de aumentar la flexibilidad del modelo. Esta elección se basa en el buen desempeño observado en modelos altamente flexibles, como el de Bosque Aleatorio, durante la competencia. Finalmente, el modelo seleccionó un total de 45 variables con coeficientes distintos de cero.

3.3. Árbol de clasificación

El uso de un árbol CART permite identificar combinaciones específicas de características que distinguen con claridad a los hogares pobres, lo que mejora la capacidad del modelo para capturar patrones complejos. Aunque su capacidad predictiva puede ser superada por los modelos de Boosting o Random Forest que veremos a continuación, su transparencia y simplicidad lo hacen valioso como herramienta base o de referencia.

Se usó la totalidad de las variables en la realización del árbol para observar los resultados con la mayor complejidad posible. En la escogencia del hiperparámetro se realizó sobre una grilla desde 0 hasta 0.03 resultando en un valor de alfa igual a 0 con un valor de la métrica ROC igual a 0.8951. Este resultado sugiere con cierta obviedad que los árboles más profundos clasifican con más precisión que los árboles con menos profundidad, sin embargo, hay maneras compensar este sobreajuste las cuales que veremos en los siguientes modelos. 4

3.4. Random Forests (Bosques Aleatorios)

3.4.1. Variables utilizadas

Otro algoritmo relevante utilizado como mecanismo clasificatorio predictivo para identificar a hogares Pobres y No-Pobres fue el de Bosques Aleatorios, también conocido como Random Forests. Este algoritmo es una mejora directa de los árboles 'bagged', pues minimiza la correlación entre los componentes. Este algoritmo se encarga de construir un número N de árboles de decisión en muestras de entrenamiento construidas con Bootstrap. Ahora, cada vez que el algoritmo considere una partición en los árboles, se escoge una muestra aleatoria de m predictores candidatos para realizar el "split"; donde $m < p$ y p es el número total de posibles predictores. Esto permite que los árboles simulados tengan predictores necesariamente distintos en algunas particiones, lo cuál hace que el resultado promedio (o

el resultado categórico mayoritario) tenga una menor varianza y produzca predicciones más acertadas. Generalmente, este procedimiento conduce a una reducción tanto en error de prueba como en el error 'Out of Bag'. Esto también hace a este algoritmo mucho más robusto a imbalances de clase en comparación con otras metodologías, como Logit. Esto es porque el modelo se construye a partir de distintas distribuciones bootstrap de los datos. Como el muestreo por bootstrap es aleatorio, se evita que el árbol esté sesgado por la clase dominante (en este caso los hogares No-Pobres). Por ello, no se realizará un rebalanceo de clases para este algoritmo.

La base de datos final contó con un total de 91 variables a nivel individuo que fueron agrupadas a nivel hogar. Para entrenar los modelos explicados en esta sección, se consideraron todas las variables de la base de datos, y adicionalmente tres subconjuntos distintos de estas variables. X_1 denota el conjunto de variables cuya varianza es distinta y lejana de cero. La base procesada tenía variables con pocas observaciones pertenecientes a una de sus clases. Estas variables impidieron la partición de algunos de los nodos de los árboles, por lo cuál se decidió estimar el modelo en base a aquellas que tuvieran clases con más observaciones, ergo mayor varianza. La explicación detallada de los conjuntos X_2 y X_3 se abordará de forma más profunda en la siguiente subsección. Estos últimos dos conjuntos representan las variables que tienen *importancia* > 500 e *importancia* > 250. La importancia de una variable en un Random Forest clasificatorio se basa en cuánto reduce la impureza (medida por el coeficiente de Gini) del modelo cada vez que se utiliza esa variable para dividir un nodo.

$$\begin{aligned}
 X_1 &= \left\{ \begin{array}{l} \text{Número de cuartos en la vivienda, Personas que duermen por cuarto,} \\ \text{Tipo de propiedad de la vivienda, Valor hipotético del arriendo,} \\ \text{Valor real del arriendo, Tamaño del hogar, Número de personas en la unidad de gasto,} \\ \text{Línea de indigencia, Línea de pobreza, Total de horas trabajadas en el hogar,} \\ \text{Total personas que trabajan por cuenta propia, Total en microempresas,} \\ \text{Total personas en pequeñas, medianas y grandes empresas,} \\ \text{Proporción de menores de 15 años, Proporción de mayores de 60 años,} \\ \text{Total mujeres en el hogar, Edad promedio del hogar, Total que cotizan a seguro social,} \\ \text{Total subsidiados, Proporción con educación superior, Grado de escolaridad promedio,} \\ \text{Tiempo total en la empresa, Ocupados, Desempleados, Inactivos,} \\ \text{Población en edad de trabajar, Promedio de horas trabajadas,} \\ \text{Proporción que cotiza pensión} \end{array} \right\} \\
 X_2 &= \left\{ \begin{array}{l} \text{Número de cuartos en la vivienda, Personas que duermen por cuarto,} \\ \text{Valor hipotético del arriendo, Valor real del arriendo, Tamaño del hogar,} \\ \text{Número de personas en la unidad de gasto, Línea de indigencia, Línea de pobreza,} \\ \text{Total de horas trabajadas en el hogar, Total personas que trabajan por cuenta propia,} \\ \text{Total personas en pequeñas, medianas y grandes empresas, Proporción de menores de 15 años,} \\ \text{Total mujeres en el hogar, Edad promedio del hogar, Total que cotizan a seguro social,} \\ \text{Total subsidiados, Proporción con educación superior, Grado de escolaridad promedio,} \\ \text{Tiempo total en la empresa, Ocupados, Desempleados, Tipo de propiedad de la vivienda,} \\ \text{Inactivos, Población en edad de trabajar, Promedio de horas trabajadas,} \\ \text{Proporción que cotiza pensión, Proporción de mayores de 60 años, Total en microempresas} \end{array} \right\} \\
 X_3 &= \left\{ \begin{array}{l} X_2, \text{Ocupados, Desempleados, Proporción que recibe ingresos adicionales, Proporción de ocupados} \\ \text{Inactivos, Población en edad de trabajar, Proporción que recibe pagos por arriendo,} \\ \text{Proporción de desempleados, Proporción de inactivos,, Proporción de prima de servicios,} \\ \text{Proporción de horas trabajadas, Proporción de trabajadores en microempresa} \\ \text{Proporción de cotizantes a pensión, Proporción de personas que trabajan solas} \\ \text{Proporción de tiempo en la empresa, Proporción de población en edad de trabajar} \\ \text{Proporción de trabajadores en gran empresa, Proporción de personas con subsidio de transporte} \end{array} \right\}
 \end{aligned}$$

3.4.2. Selección de Hiperparámetros

Para estimar y comparar la bondad de un Random Forest, se utilizan pruebas sobre tres principales hiperparámetros:

m = número de predictores escogidos aleatoriamente para realizar la partición de un nodo

B = número de árboles construidos usando muestras bootstrap

z = número mínimo de observaciones por nodo

Para estimar los valores de m y z , se utilizó validación cruzada K-fold con 5 particiones antes de correr cada iteración realizada de Random Forest utilizando el paquete 'caret' de R. Para la estimación de m , se iteró sobre los valores 6, 8, 9, 10. Para cada uno de los modelos excepto el primero (que será explicado a continuación), en donde se iteró sobre 6, 8, 9, 30. La escogencia del rango para este hiperparámetro tomó en cuenta dos factores: 1). La métrica "benchmark" de m para estos modelos ($\sqrt{m}$), y 2). Un intento de comparación con 'bagging' (usando $m = p$). El segundo factor fue exitoso cuando se iteró hasta 30, el número de predictores en $\mathbf{X}_1$. Sin embargo, la estimación utilizando $m = p$ tuvo el peor desempeño en términos de ROC para dicho modelo y tuvo un alto costo computacional. Por ello, se consideró plausible una estimación con alto énfasis en el benchmark $\sqrt{m}$ y valores cercanos a él. Por lo general, se esperaba un valor de m cercano a 9 o a 10, dado que los valores de p eran casi siempre cercanos al número de variables total de la base procesada (91). Sin embargo, se incluyeron valores como 6 y 8 considerando la posible alta cantidad de predictores importantes y altamente correlacionados entre ellos. Un m más bajo podría neutralizar aún más el efecto correlación cuando surge este escenario. La grilla de búsqueda de z iteró sobre 1, 10, 100, 500, 1000 para algunos modelos, generalmente se utilizó $z = 1$. Como este parámetro mide la profundidad y por ende la complejidad del árbol, preferimos construir árboles altamente profundos. Esto es porque como Random Forest permite reducir la correlación entre árboles, es posible construir modelos sobre-especificados con una mucha menor penalización en términos de capacidad predictiva. El valor de $B = 500$ permaneció fijo durante el proceso de validación cruzada y en la estimación de los modelos. Inicialmente también se realizó una grilla para este parámetro, pero se encontró que las ganancias en error 'Out of Bag' eran mínimas después de aumentar B .

Se estimaron cuatro versiones de este algoritmo, con características distintas y aproximaciones variadas para fijar sus hiperparámetros.

Random Forest 1: El primer modelo utilizó las variables en $\mathbf{X}_1$. Estas variables cumplieron el requisito de tener varianza diferente y lejana de cero. Para este modelo, se iteró sobre una grilla con los valores 6, 8, 9, 30 para m y una grilla con los valores 1, 10, 100, 500 y 1000 para z . Como explicado anteriormente, se buscó estimar el modelo con valores cercanos a ($\sqrt{m}$) y a p . También se iteró sobre distintos valores de mínimo de observaciones por nodo, pero se escogería 1 para maximizar la complejidad del modelo. Esto siempre será el caso en el resto de nuestros modelos Random Forest. El proceso de validación cruzada con $K = 5$ folds sugirió la utilización de $m = 6$ y $z = 10$. Se utilizó la medida de ROC como principal métrica de desempeño. Como explicado anteriormente, los Random Forests son más robustos al desbalance de clases, por lo cuál la utilización del ROC puede ser una medida precisa de la capacidad de discriminación del modelo sin un umbral particular. Para estos dos hiperparámetros, el AUC-ROC fue el más alto (0,9234566). No obstante, fue el peor de los cuatro modelos en cuestión de su F1; con un valor de 0.638. 5

Random Forest 2: En el segundo modelo se utilizó la totalidad de las variables. En este modelo se iteró con la misma grilla de m pero con el ánimo de aumentar la profundidad de los arboles se uso un valor $m = 1$. El resultado de esta validación con $K = 5$ folds arrojó una combinación de $m = 10$, $z = 1$

con una métrica AUC-ROC de (0,9438204) y un valor F1 de 0.6703. 6

Random Forest 3: A partir de este modelo se realizó una selección de variables con el fin de aumentar el desempeño predictivo de cada nodo final. Con los resultados de modelo número 2 se estimó la importancia de todas las variables obteniendo un rango de 1,6 hasta 2392,3. Dado el rango de importancia se escogió un punto de corte de 1000 para filtrar las observaciones más importantes, esas variables son las que comprenden el conjunto X_2 . Este modelo se iteró con una grilla m de 6, 8, 9, 10, un valor z de 1 y un valor B de 500. Los resultados de la métrica AUC-ROC fue de (0,9342165) y el valor F1 fue de 0.6881 con una combinación $m = 10$ y $z = 1$, incrementando el desempeño de manera considerable. 7

Random Forest 4: En este último modelo se escogió un corte de 250 en la importancia de las variables que conformaron el modelo, estas variables componen el conjunto X_3 . Haciendo estimaciones de prueba con este nuevo conjunto de variables observamos una disminución en el error OOB que evidenciamos era una buena aproximación al desempeño de la predicción con F1, por este motivo se decidió probar el modelo con un número de árboles mucho mayor. De nuevo se realizó una iteración sobre los valores 6, 8, 9, 10 para m , se escogió un valor $z = 1$ y un valor $B = 1000$. Los resultados para la mejor combinación $m = 10$ arrojaron un AUC-ROC de (0,9341952) y un valor F1 igual a 0,6940 siendo el modelo con mejor desempeño de predicción. 8

3.5. Adaptive Boosting (Adaboost)

3.5.1. Tratar desbalance de clases

La Figura 1 ilustra el desbalance de clases de la variable Pobre en los datos de entrenamiento. La variable tiene dos niveles *Sí* para las personas clasificadas como pobres según el DANE (2018) y *No* para las personas que no fueron clasificadas como pobres. La base de datos de entrenamiento cuenta con 33024 pertenecientes a la clase *Sí* y 131936 pertenecientes a la clase *No* lo que corresponde a un desbalance de alrededor de 25%. Es decir, por cada observación de clase *Sí* hay en promedio cuatro observaciones de la clase *No*.

Para tratar este desbalance se implementó una estrategia híbrida de rebalanceo de clases. Se triplico el tamaño de la clase *Sí* usando muestreo con remplazo y se disminuyó en una cuarta parte el tamaño de la clase *No* seleccionando aleatoriamente observaciones. La idea detrás del proceso fue añadir dos observaciones por cada observación de la clase *Sí* y remover una observación de la clase *No* para dejar balanceada a la variable Pobre.

3.5.2. Variables utilizadas

Inicialmente se buscó estimar el modelo con todas las variables disponibles en la base de entrenamiento consolidada después de la limpieza y el pre-procesamiento. Sin embargo, en la base estaban presentes variables con varianza cercana a cero que impidieron la estimación del modelo y su respectiva validación cruzada. Estas variables tenían muy pocas observaciones pertenecientes a una de sus clases. Por lo cual, cuando se realizó la validación cruzada hubo folds donde para estas variables no había observaciones en una sus clases y por ende no se pudo usar las variables para hacer una partición. Cuando se intentó agregar los resultados de los folds donde si se usó una de estas variables para hacer una partición con los folds donde no se usaron se presentó un error (el software consideraba que se estaba introduciendo una variable en unos casos y no en otros y no pudo hacer la agregación de resultados). En consecuencia, se decidió estimar el modelo con todas las variables en la base de entrenamiento cuya varianza no fuera cercana a cero.

Variables incluidas en el modelo fueron:

(i) **Características vivienda:** Número de cuartos de la vivienda, Número de personas que duer-

men por cuarto, Tipo de propiedad sobre la vivienda donde se vive y Valor hipotético que se paga por el arriendo. **(ii) Composición del hogar:** Tamaño del hogar, Número de personas en la unidad de gasto, Mujeres en el hogar, Menores de 15 años, Mayores de 60 y edad promedio del hogar. **(iii) Educación:** Proporción del hogar con educación superior y Grado escolar promedio. **(iv) Situación laboral:** Ocupados en el hogar, Desempleados, Inactivos, PET (Personas en el hogar en edad de trabajar), Horas trabajadas por lo miembros del hogar, Tiempo que llevan las personas en sus empresas y Promedio de horas trabajadas en el hogar. **(v) Tipo de empresa:** Personas en el hogar que trabajan solas, Personas en el hogar que trabajan en una microempresa (2 a 10 trabajadores), Personas que trabajan en una empresa pequeña (11 a 30 trabajadores), Personas que trabajan en una empresa mediana (31 a 100 trabajadores) y Personas que trabajan en una gran empresa (101 o más trabajadores). **(vi) Seguridad social:** Personas que cotizan seguro social, Personas subsidiadas por el seguro social y Proporción de personas que cotizan pensión. **(vii) Pobreza:** Línea de indigencia y Línea de pobreza.

3.5.3. Selección de Hiperparámetros

Para entrenar el modelo Adaboost fue necesario seleccionar los siguientes hiperparámetros: el número de árboles, la profundidad de los árboles y los pesos para ponderar las observaciones mal clasificadas. Inicialmente se utilizó una grilla pequeña con una sola combinación de hiperparámetros para probar que el modelo corriera correctamente. Posteriormente, se amplió la grilla para probar distintas combinaciones de número árboles y profundidad y se obtuvo que los hiperparámetros que generaron el mejor rendimiento en el modelo eran los más altos incluidos en la grilla. Finalmente, se optó por correr el modelo una última vez usando una grilla con una sola combinación de hiperparámetros que eran más altos que la mejor combinación de la grilla anterior. Se decidió no variar el ponderador de pesos (se mantuvo Freund) para mantener el mismo utilizado en clase y para reducir las demandas computacionales de la estimación. Asimismo, en la última estimación se decidió no utilizar una grilla más amplia debido a las demás computacionales de la estimación.

4. Modelo final

El modelo con mejor desempeño en Kaggle fue un modelo de Random Forest luego de realizar una selección de predictores relevantes, una validación cruzada y un mayor número de árboles. Dada la gran cantidad de variables disponibles para la predicción se realizó una selección de las variables más importantes de una predicción con unos hiperparámetros de 6 para m y 1 para z midiendo esta importancia por la disminución en la impureza de los nodos finales. De estas 91 variables iniciales se terminaron escogiendo las variables con una importancia mayor a 250 que están compuestas por el conjunto de variables X_3 .

En los primeros lugares se encuentran variables fuertemente asociadas al mercado laboral y al acceso a servicios básicos. La proporción de ocupados lidera la lista, lo que resalta la relevancia de la inserción laboral como factor clave para reducir la pobreza. Le sigue el arriendo hipotético, una variable que refleja el valor de mercado de la vivienda habitada, lo que puede estar captando tanto condiciones materiales del hogar como su ubicación (aspectos ligados al bienestar). También se destacan variables como el promedio de edad y la proporción de personas con seguro subsidiado, que permiten captar características demográficas y el grado de dependencia del hogar en programas sociales, este último asociado frecuentemente a condiciones de vulnerabilidad. Más abajo en la jerarquía encontramos variables como el factor de expansión, las líneas de pobreza e indigencia, o la proporción en educación superior. Aunque estas variables tienen relevancia, su poder predictivo en el modelo es menor. Esto puede deberse a que son más indirectas (como el factor de expansión, que es de diseño muestral) o captan fenómenos más agregados que no siempre se traducen en una mejor distinción entre hogares pobres y no pobres a nivel individual. Las variables menos importantes son en su mayoría estructurales o altamente específicas. Por ejemplo, la proporción de trabajadores en gran empresa, el número de cuartos en los que duermen, o la proporción de personas con subsidio de transporte, si bien informativas, no aportan significativamente a la capacidad discriminativa del modelo. En general, estas

variables presentan menor variación entre hogares o están correlacionadas con otras más predictivas, lo que reduce su importancia relativa. Una observación clave es que muchas variables relacionadas con la estructura del hogar (como el número de personas, de cuartos o el dominio territorial) tienen menor peso que aquellas vinculadas al empleo y condiciones económicas directas. Esto subraya que las condiciones de inserción laboral y la seguridad social son, en este modelo, determinantes más efectivos para predecir la pobreza que las características físicas del hogar o su composición demográfica.

Luego, se realizó una validación cruzada con una grilla de 6, 8, 9 y 10 para m , un número de árboles igual a 1000 y un número mínimo de observaciones por nodos finales igual a 1. La idea detrás de esta predicción es que el modelo haga más particiones en las variables más importantes del modelo con la mayor especificidad posible que luego va a ser suavizada por el número de árboles. El resultado de esta validación cruzada fue un hiperparámetro $m = 10$, obteniendo un error OOB de 11,27% y un resultado de F1 igual a 0,6940.

Este modelo alcanzó un F1 de 0.6940, superando tanto a los demás modelos de Random Forest como a todos los modelos estimados con AdaBoost. Random Forest tiene la ventaja de reducir la varianza al combinar múltiples árboles entrenados sobre muestras aleatorias, y al limitar el número de variables consideradas en cada división, introduce diversidad entre árboles sin perder capacidad predictiva. En comparación, el segundo mejor modelo fue también un Random Forest con la misma configuración pero solo 600 árboles. Este modelo obtuvo un F1 de 0.6914, ligeramente inferior. La diferencia puede explicarse por el menor número de árboles, lo que implica una menor reducción de la varianza del modelo. Aumentar la cantidad de árboles en un ensamble mejora la estabilidad de las predicciones hasta cierto punto, lo que justifica que el modelo con 1000 árboles tuviera un rendimiento ligeramente superior. Otro modelo de Random Forest, que utilizó solo variables con importancia mayor a 500, también quedó por debajo en desempeño (F1 = 0.6881). Aunque mantuvo el mismo número de árboles (500) y la misma configuración general, la exclusión de variables que sí aportaban valor predictivo (con importancia entre 250 y 500) probablemente redujo la riqueza del espacio predictor. En Random Forest, la importancia de las variables puede ayudar a reducir la dimensionalidad, pero si se selecciona un umbral demasiado alto, se corre el riesgo de dejar fuera información valiosa, lo cual parece haber ocurrido en este caso.

Por su parte, los modelos con AdaBoost, aunque cercanos en desempeño, fueron superados por los de Random Forest. El mejor de ellos, con 500 árboles y profundidad 8, alcanzó un F1 de 0.6848. Este modelo utilizó un esquema de rebalanceo que aumentó artificialmente la clase minoritaria mediante muestreo con reemplazo y redujo la clase mayoritaria eliminando observaciones. Si bien este enfoque es común para enfrentar el desbalance, puede tener efectos adversos si introduce observaciones repetidas que no agregan nueva información o si elimina ejemplos representativos de la clase mayoritaria. Además, este modelo utilizó todas las variables cuya varianza no era cercana a cero, sin una selección posterior por importancia, lo que probablemente introdujo ruido o redundancia en la predicción, como se observó con el Random Forest 1. Otro modelo de AdaBoost con 900 árboles y la misma profundidad no logró superar al de 500 árboles, con un F1 de 0.6838. A pesar del aumento en el número de iteraciones, el rendimiento no mejoró, lo que sugiere que el modelo alcanzó un punto de saturación donde seguir agregando clasificadores no aporta mejoras significativas. El boosting puede ser sensible al sobreajuste si no se ajustan adecuadamente la profundidad de los árboles o el número de iteraciones. En este caso, la combinación de un número alto de árboles, profundidad elevada y un conjunto amplio de variables podría haber aumentado el riesgo de sobreajuste, afectando el desempeño general.

Finalmente, el modelo de AdaBoost con solo 100 árboles fue el que tuvo el peor desempeño (F1 = 0.6776). Aunque mantenía la misma estructura y rebalanceo que los otros modelos de AdaBoost, el número limitado de árboles impidió que el algoritmo capturara suficientemente los patrones del conjunto de entrenamiento. En boosting, cada árbol se entrena para corregir los errores del anterior, por

lo que usar pocos árboles significa que se abandona el proceso de refinamiento prematuramente, lo que se traduce en menor capacidad de ajuste.

5. Conclusión

Clasificar a los hogares como pobres o no es indispensable para que el estado colombiano pueda focalizar de manera efectiva sus recursos escasos para aliviar la pobreza de los hogares más vulnerables. A lo largo de presente trabajo se aprovecharon los datos de la misión para el “Empalme de las Series de Empleo, Pobreza y Desigualdad - MESE” (DANE 2018) para identificar si los hogares son pobres o no. Para obtener esta clasificación se utilizaron cinco algoritmos de clasificación (Regresión Logística, Elastic Net, CART, Random Forest y Adaboost) entre estos modelos los que obtuvieron mejores resultados fueron Random Forest y Adaboost. Entre los últimos dos modelos mencionados Random Forest generó la mejor predicción.

La ventaja del modelo se debió a una combinación estratégica de decisiones metodológicas: trabajar con la muestra original sin aplicar técnicas de rebalanceo, seleccionar únicamente las variables más relevantes según su importancia predictiva, y utilizar un número elevado de árboles, lo que permitió reducir la varianza sin incurrir en sobreajuste. En contraste, modelos como AdaBoost aplicaron rebalanceo de clases mediante sobremuestreo y submuestreo, lo cual introdujo redundancia y pérdida de información representativa. Por su parte, los modelos estimados con regresión logística y Elastic Net, al asumir relaciones lineales entre las variables y la variable dependiente, presentaron limitaciones para capturar interacciones y umbrales no lineales. Asimismo, el modelo CART, aunque interpretativo y útil para explorar reglas claras, no alcanzó el nivel de generalización ofrecido por el ensamblaje robusto del Random Forest. Otra característica importante del mejor modelo fue la elección de las variables. Al restringirse a aquellas con mayor importancia predictiva, el modelo se centró en los factores más determinantes. Esta selección no solo optimizó el rendimiento del modelo, sino que además sugiere que existen patrones bien definidos en los datos que pueden ser aprovechados eficientemente sin necesidad de incluir la totalidad de las 91 variables disponibles.

Finalmente, con el objetivo de encontrar modelos más precisos en la predicción se desearía utilizar grillas más grandes para la hiperparametrización. Dado que los resultados muestran mejor desempeño en modelos con un mayor número de árboles y mayor especificación, tener una mayor capacidad computacional para correr los modelos y encontrar hiperparámetros dentro de un rango más grande realmente valioso para que los modelos aumenten su desempeño.

6. Anexos

Tabla 1. Estadísticas descriptivas Pobres

Estadísticas	Mean	St. Dev.	Min	Max	Median
Número cuartos	3.032	1.127	1	14	3
Arriendo	138,019.400	195,453.600	0	1,900,000	0
Número personas	4.134	2.026	1	28	4
Horas Trabajadas	52.458	43.679	0	558	48
Mujer	2.236	1.348	0	14	2
Menores 15	1.447	1.298	0	14	1
Edad	30.627	16.228	5.667	101.000	25.500
Seguridad S Subsidiado	2.287	1.678	0	14	2
P Ed Primaria	0.329	0.288	0.000	1.000	0.333
P Ed Secundaria	0.202	0.229	0.000	1.000	0.167
P Ed Media	0.187	0.223	0.000	1.000	0.143
P Ed Superior	0.096	0.199	0.000	1.000	0.000
Tiempo empresa	105.464	160.978	0	1,833	36
Ocupados	1.257	0.991	0	11	1
Inactivos	1.446	1.170	0	11	1
P cotiza pensión	0.098	0.279	0.000	1.000	0.000
Seguridad Social	2.734	1.596	0	16	2

Tabla 2. Estadísticas descriptivas No Pobres

Estadísticas	Mean	St. Dev.	Min	Max	Median
Número cuartos	3.480	1.250	1	98	3
Arriendo	170,982.300	275,891.800	0	1,900,000	0
Número personas	3.082	1.640	1	22	3
Horas Trabajadas	71.114	49.591	0	640	60
Mujer	1.616	1.099	0	13	1
Menores 15	0.578	0.832	0	7	0
Edad	39.145	16.603	6.333	102.000	35.500
Seguridad S subsidiado	0.930	1.296	0	12	0
P Ed Primaria	0.229	0.302	0.000	1.000	0.000
P Ed Secundaria	0.148	0.236	0.000	1.000	0.000
P Ed Media	0.230	0.289	0.000	1.000	0.000
P Ed Superior	0.307	0.349	0.000	1.000	0.250
Tiempo empresa	134.885	169.014	0	2,077	69
Ocupados	1.566	1.026	0	14	1
Inactivos	0.923	0.963	0	9	1
P cotiza pensión	0.406	0.438	0.000	1.000	0.333
Seguridad Social	2.479	1.368	0	19	2

Nota: Las variables que tienen enfrente una P son la proporción de miembros del hogar que cumplen la condición. La variable Tiempo Empresa hace referencia al número de meses en la empresa

Tabla 3. Top 10 combinaciones de α y λ según $F1$

α	λ	F1
0.4	0.004451	0.926726
0.2	0.004451	0.926662
0.1	0.004451	0.926643
0.6	0.004451	0.926614
0.5	0.004451	0.926613
0.7	0.004451	0.926570
0.8	0.004451	0.926517
0.3	0.004451	0.926504
0.9	0.004451	0.926389
1.0	0.004451	0.926301

Tabla 4. Desempeño del Modelo según el Valor de cp

Iteración	cp	ROC	Sensibilidad	Especificidad	Precisión
1	0.000	0.895	0.614	0.918	0.857
2	0.001	0.880	0.563	0.946	0.869
3	0.002	0.841	0.527	0.948	0.864
4	0.003	0.835	0.474	0.956	0.860
5	0.004	0.828	0.501	0.940	0.852
6	0.005	0.828	0.500	0.940	0.852
7	0.006	0.828	0.500	0.940	0.852
8	0.007	0.828	0.500	0.940	0.852
9	0.008	0.828	0.511	0.937	0.851
10	0.009	0.810	0.502	0.936	0.849
11	0.010	0.742	0.395	0.955	0.843
12	0.011	0.742	0.395	0.955	0.843
13	0.012	0.742	0.395	0.955	0.843
14	0.013	0.742	0.395	0.955	0.843
15	0.014	0.742	0.395	0.955	0.843

Tabla 5. Métricas de desempeño Hiperparámetros Random Forest 1

m	z	splitrule	ROC	Sens	Spec	Accuracy
6	1	gini	0.923	0.598	0.950	0.880
6	10	gini	0.923	0.595	0.951	0.880
6	100	gini	0.923	0.571	0.955	0.878
6	500	gini	0.917	0.516	0.960	0.871
6	1,000	gini	0.913	0.477	0.963	0.866
8	1	gini	0.922	0.602	0.949	0.879
8	10	gini	0.923	0.599	0.950	0.880
8	100	gini	0.923	0.580	0.954	0.879
8	500	gini	0.918	0.532	0.957	0.872
8	1,000	gini	0.914	0.494	0.960	0.867
10	1	gini	0.922	0.604	0.948	0.879
10	10	gini	0.923	0.602	0.949	0.880
10	100	gini	0.923	0.584	0.953	0.879
10	500	gini	0.918	0.541	0.956	0.873
10	1,000	gini	0.913	0.506	0.958	0.867
30	1	gini	0.917	0.607	0.943	0.875
30	10	gini	0.918	0.603	0.944	0.876
30	100	gini	0.920	0.593	0.948	0.877
30	500	gini	0.915	0.558	0.950	0.872
30	1,000	gini	0.909	0.524	0.951	0.866

Tabla 6. Métricas de desempeño Hiperparámetros Random Forest 2

m	z	splitrule	ROC	Sens	Spec	Accuracy
6	1	gini	0.933	0.574	0.960	0.883
8	1	gini	0.934	0.593	0.958	0.885
9	1	gini	0.935	0.599	0.957	0.885
10	1	gini	0.935	0.604	0.956	0.885


Tabla 7. Métricas de desempeño Hiperparámetros Random Forest 3

m	z	splitrule	ROC	Sens	Spec	Accuracy
6	1	gini	0.933	0.590	0.957	0.883
8	1	gini	0.934	0.602	0.956	0.885
9	1	gini	0.934	0.607	0.955	0.885
10	1	gini	0.934	0.612	0.954	0.886

Tabla 8. Métricas de desempeño Hiperparámetros Random Forest 4

m	z	splitrule	ROC	Sens	Spec	Accuracy
6	1	gini	0.933	0.589	0.957	0.883
8	1	gini	0.934	0.603	0.955	0.885
9	1	gini	0.934	0.608	0.955	0.885
10	1	gini	0.934	0.612	0.954	0.886

Fig. 1. Desbalance de clases de pobreza



Nota: el desbalance ilustrado en esta figura corresponde a los datos de entrenamiento.

Tabla 9. Métricas de desempeño hiperparámetros Adaboost

Profundidad árboles	Número de árboles	F
4	100	0.8415896
4	500	0.8500464
5	100	0.8462672
5	500	0.8572333
6	100	0.8499312
6	500	0.8686682
7	100	0.8556029
7	500	0.8913321
8	100	0.8680074
8	500	0.9208548
8	900	0.9319328

Nota: La última fila contiene los resultados de la última combinación de hiperparámetros. Esta combinación se corrió en solitario a diferencia de las otras que se corrieron en la misma grilla. Se mantuvo constante el ponderador (Freund) de los errores en todas las estimaciones

Bibliografía

1. Camacho, A. & Conover, E. (2011). *Volunteering, Unpaid Care Work and Gender in Lower-Income Countries*. *American Economic Journal: Economic Policy*, 3(2), 41–65. <https://doi.org/10.1257/pol.3.2.41>
2. Departamento Administrativo Nacional de Estadística (DANE). (2018). *Medición de Pobreza Monetaria y Desigualdad 2018*. <https://microdatos.dane.gov.co/index.php/catalog/608>
3. Departamento Nacional de Planeación (DNP). (2021). *¿Qué es el Sisbén?* <https://www.sisben.gov.co/Paginas/que-es-sisben.html>
4. Departamento Nacional de Planeación (DNP). (2021). *Conoce el Sisbén IV*. https://www.sisben.gov.co/Paginas/conoce_el_sisben.html
5. Secretaría Distrital de Planeación. (2021). *Preguntas Frecuentes Sisbén*. <https://www.sdp.gov.co/gestion-estudios-estrategicos/sisben/preguntas-frecuentes>